

Badanie działania metod Uczenia Maszynowego

Metodologia i przygotowanie danych

Wszystkie klasyczne algorytmy uczenia maszynowego (Random Forest, KNN, Decision Tree, Gradient Boosting) zostały przetestowane przy użyciu jednolitej metodologii, co pozwala na rzetelne porównanie ich wyników.

Zakres badań i wybór cech:

Eksperymenty przeprowadzono na zbiorze demograficznym, zawierającym szczegółowe informacje z ankiet dotyczących życia małżeńskiego. Zbiór liczy ponad 8 000 obserwacji i obejmuje po preprocessingu 39 cech, w tym m.in. wiek zawarcia małżeństwa, wyznawaną religię, poziom zarobków czy typ zawartego małżeństwa (aranżowane vs z miłości).

Dla każdego modelu zrealizowano dwa oddzielne zadania:

1. **Klasyfikację zmiennej `Divorce_Status`** (2 klasy: Brak Rozvodu, Wziął Rozwód).
2. **Regresję zmiennej `Years_Since_Marriage`** (Staż małżeński).

W obydwu zadaniach rygorystycznie usunięto wzajemne przecieki informacji (tzw. data leakage). Przykładowo, przy klasyfikacji rozvodu usunięto wysoce skorelowane dane "z przyszłości", wymuszając na algorytmach naukę wyłącznie w oparciu o demograficzne i społeczne cechy "z przeszłości" pary.

Preprocessing:

Proces przygotowania danych obejmował:

- **Imputację danych:** Uzupełnianie brakujących wartości medianą (cechy numeryczne) lub wartością najczęstszą (cechy kategoriyczne).
- **One-Hot Encoding:** Przekształcenie wszystkich zmiennych kategoriycznych w binarne cechy numeryczne.
- **Balansowanie Klas:** Użycie wbudowanych mechanizmów hiperparametrycznych (`class_weight='balanced'`), co było bezwzględnie konieczne ze względu na drastyczną mniejszość klasy par rozwiedzionych.

Walidacja:

Do oceny jakości każdego modelu wykorzystano stabilny podział Train/Test na proporcji 80/20. Zamiast standardowej k-krotnej walidacji krzyżowej zastosowano podejście oparte na testowaniu różnorodnych ziaren losowości (ang. seeds = [42, 43, 44]), a ostateczne wyniki klasyfikacji (Accuracy, Balanced Accuracy) oraz regresji (RMSE, MAE, R^2) stanowią rygorystyczną średnią. Chroni to model przed przypadkowym trafieniem na "dobry" zbiór testowy.

Procedura testowa:

Zastosowano metodę izolacji parametrów (ceteris paribus). Każdy parametr badano osobno w siatce Grid Search 1D, przy stałych wartościach bazowych dla pozostałych ustawień, co pozwala na izolowane obserwowanie wariacji.

1. Model Random Forest

1.1. Czym jest Random Forest i dlaczego działa?

Random Forest (las losowy) to wiodąca metoda uczenia zespołowego (ensemble learning), która opiera się na budowie kilkudziesięciu lub kilkuset niezależnych drzew decyzyjnych i połączeniu ich odpowiedzi w ostateczny wynik. Idea algorytmu opiera się na koncepcji "mądrości tłumu": wiele niezależnych, słabych modeli popołniających zróżnicowane błędy, połączonych w agregację, potrafi wydać lepszy i stabilniejszy wyrok niż pojedynczy, skomplikowany model.

Każde drzewo w lesie widzi tylko wycinek (losową próbkę typu bootstrap) danych treningowych i ma dostęp tylko do ułamka cech z ankiety. W zadaniu klasyfikacji wynik jest efektem demokratycznego głosowania, a w regresji jest średnią ze wszystkich drzew. To uśrednianie uodparnia model na przeuczenie (overfitting), stanowiące zmoę pojedynczych Drzew Decyzyjnych.

Konfiguracja bazowa modelu: klasyfikacja: n_estimators=100, max_depth=10, min_samples_split=2 regresja: n_estimators=100, max_depth=10, min_samples_split=2

1.2. Wpływ liczby drzew (n_estimators)

Parametr n_estimators kontroluje liczbę drzew tworzących las. Jest to jeden z nielicznych parametrów, dla których zwiększanie wartości zazwyczaj nie pogarsza

wyników, lecz podlega tzw. prawu malejących korzyści (z każdym kolejnym drzewem zyskujemy na jakości coraz mniej, aż do wypłaszczenia).

n_estimators	Test Balanced Acc.	Test RMSE
50	0.5000	14.248
100	0.5000	14.228
200	0.5000	14.228
300	0.5000	14.220

Wyniki perfekcyjnie odzwierciedlają założenia algorytmu. Największy "skok" stabilizacyjny (dla RMSE) następuje na progu 100 drzew (spadek do 14.228). Dalsze dokładanie estymatorów (nawet aż do 300) tylko nieznacznie podbija wynik o tysięczne części, zwiększając natomiast radykalnie koszty obliczeniowe. Z punktu widzenia optymalizacji, 100 drzew stanowi "złoty środek".

1.3. Wpływ głębokości drzew (max_depth)

Parametr max_depth ogranicza maksymalną głębokość pojedynczego drzewa. Bezpośrednio kontroluje więc złożoność ułamkową modelu i wpływa na kompromis bias-variance. Bardzo duże drzewa mogą teoretycznie dopasować się do szumu w danych.

max_depth	Test Balanced Acc.	Test RMSE
5	0.5000	14.151
10	0.5000	14.228
15	0.4999	14.387
None	0.4999	14.412

W przeciwieństwie do pojedynczego Drzewa Decyzyjnego, Random Forest wykazuje tu olbrzymią wręcz elastyczność. Pozostawienie drzew bez limitu wysokości (None) doprowadziło do minimalnego pogorszenia wyniku (wzrost RMSE do zaledwie 14.41), udowadniając tym samym, że wbudowany w RF mechanizm uśredniania świetnie redukuje wariancję z przeuczonych gałęzi. Najlepszy punkt operacyjny dla regresji w tych danych odnotowano przy silnym cięciu drzew na poziomie głębokości równej 5.

1.4. Wpływ minimalnej liczby próbek (min_samples_split)

Parametr ten definiuje, jak duża (w sensie liczności) musi być populacja węzła w drzewie, aby algorytm zezwolił na jego dalszy podział. Większe wartości "chronią" drzewo przed ślepym dzieleniem dla pojedynczych obserwacji w danych.

min_samples_split	Test Balanced Acc.	Test RMSE
2	0.5000	14.228
5	0.5000	14.233
10	0.5000	14.234
20	0.5000	14.226

Dla tak zróżnicowanych danych demograficznych, zmiana tego parametru od wartości 2 do aż 20 nie przyniosła mierzalnych odchyień w poziomie regresji. Oznacza to, że podziały w wyższych partiach drzew leśnych są na tyle dominujące decyzyjnie, że drobne cięcia "na dole" drzewa (na poziomie pojedynczych liści) kompletnie rozmywają się w sile uśredniania 100 estymatorów.

1.5. Podsumowanie analizy Random Forest

Random Forest okazał się fenomenalnie "twardym" algorytmem. W zadaniu regresji model ugruntował błąd w okolicach 14.2 lat, niemalże całkowicie uodparniając się na zabiegi manipulacji w siatce grid. Pokazuje to, że RF osiągnął sufit możliwości informacyjnych zakodowanych w pliku CSV. Najważniejsze wnioski to: (1) 100 drzew jest wystarczającą wartością produkcyjną, (2) głębokość rzędu 5 jest wystarczająca, głębsze drzewa jedynie przedłużają czas treningu bez wartości predykcyjnej.

2. Model K-Nearest Neighbors (KNN)

2.1. Czym jest KNN i jak działa?

K-Nearest Neighbors (K najbliższych sąsiadów) to algorytm typu *lazy learning* oraz *instance-based learning*. Oznacza to, że nie odbywa się tu klasyczny proces "trenowania" wag matematycznych. Model zapamiętuje zbiór treningowy, a przy pojawieniu się pacjenta testowego, mierzy odległość geometryczną tego pacjenta do wszystkich osób w zapamiętanej bazie. Odpowiedź wydawana jest w drodze

wyciągnięcia średniej arytmetycznej na podstawie K-najbliższych mu (najbardziej podobnych demograficznie) pacjentów.

Niezbędnym wymogiem dla KNN jest standaryzacja danych numerycznych, gdyż w przeciwnym razie jedna kolumna o dużej rozpiętości odchyłeń (np. zarobki w setkach tysięcy) całkowicie zdeklasowałaby małe numerycznie kolumny (jak Liczba Dzieci), niszcząc miarę odległości geometrycznej.

2.2. Wpływ liczby sąsiadów (n_neighbors)

Parametr n_neighbors (K) determinuje wielkość rzeszy punktów referencyjnych dla nowego pacjenta. Małe K prowadzi do chaotycznego zapamiętywania (overfittingu lokalnego), wysokie K prowadzi do wygładzenia modelu i ignorowania rzadkich odstępstw.

n_neighbors	Test Balanced Acc.	Test RMSE
3	0.5033	16.334
5	0.5030	15.391
11	0.4997	14.753
21	0.5000	14.502

Badania dobitnie potwierdzają teoretyczną wadę algorytmu. Decyzja w oparciu o poradę jedynie 3 sąsiadów skutkowałą drastycznym wzrostem błędu przewidywań (RMSE > 16.3). Wraz ze stygmatyzacją tego szumu w drodze wyboru aż 21 sędziów, błąd modelu malał asymptotycznie do progu akceptowalnego (14.50).

2.3. Wpływ sposobu ważenia sąsiadów (weights)

Sprawdzono, czy włączenie funkcji ważenia sąsiadów według dystansu polepszy sprawę – w wariancie 'distance', sąsiad ułożony bliżej w 39-wymiarowej przestrzeni miał więcej do powiedzenia niż sąsiad ułożony tuż na granicy pola widzenia. Wariant 'uniform' traktuje głosy sąsiadów jako równe.

weights	Test Balanced Acc.	Test RMSE
uniform	0.4997	14.753
distance	0.4994	14.830

Eksperyment pokazał ciekawe odchylenie – uśrednianie równomierne (uniform) spisano się ułamkowo lepiej (spadek z 14.83 na 14.75). Może to oznaczać, że ze względu na naturę zachowań społecznych, pojedynczy sąsiad leżący bardzo blisko naszego punktu stanowi anomalię (tzw. zjawisko *outliera* socjologicznego) i nałożenie na jego głos mocniejszej wagi psuje globalny wniosek wyciągnięty przez grupę.

2.4. Wpływ metryki odległości (p)

Parametr p określa definicję "bliskości" między dwiema osobami. $p=1$ to metryka Manhattan (suma absolutna różnic osi), a $p=2$ to tradycyjna metryka Euklidesowa (odległość w linii prostej z użyciem Pitagorasa).

p	Test Balanced Acc.	Test RMSE
1 (Manhattan)	0.5000	14.744
2 (Euclidean)	0.4997	14.753

Błędy dla regresji są w zasadzie identyczne, z marginalnym wskazaniem na logikę metryki *Manhattan* (14.74). Udowadnia to, że podniesienie różnicy do kwadratu w przestrzeni socjologicznej nie obciąża modelu korzyściami, a w środowisku wysokowymiarowym (39 cech) proste sumowanie różnic (jak w metryce miejskiej) jest równie skuteczne i bezpieczniejsze dla wysoce odrębnych *outlierów*.

2.5. Podsumowanie analizy KNN

K-NN spisał się bezsprzecznie gorzej od metody Lasów Losowych, plasując swój próg błędów wyraźnie powyżej metody Ensemble. Taki stan rzeczy wywołany jest tzw. "Przekleństwem Wymiarowości" (Curse of Dimensionality). W świecie, gdzie definiujemy sąsiada poprzez równoczesną bliskość aż 39 przeróżnych osi danych społecznych (np. wiek, wykształcenie, posag), de facto wszyscy stają się od siebie niesamowicie oddaleni. Metryka K-NN jest bezużyteczna w tak wysoko rozwarstwionym układzie ankietowym.

3. Model Gradient Boosting

3.1. Czym jest Gradient Boosting i jak działa?

Gradient Boosting to zaawansowana metoda uczenia zespołowego (Ensemble), stanowiąca odpowiedź na słabości Lasów Losowych. Zamiast budować niezależne drzewa uśredniane na koniec, w GB drzewa są sadzone sekwencyjnie. Drzewo startowe dokonuje zgrubnej predykcji. Następne drzewo uczy się nie tyle na surowych danych, co "poluje" i niweluje wyłącznie te błędy (tzw. rezidua), których nie potrafiło rozwiązać drzewo poprzednie. Proces jest iteracyjny.

Chociaż GB potrafi dopasować się do najdrobniejszych zawłości nieliniowych relacji międzyludzkich (co czyni go najlepszym narzędziem Kaggle'a w erze przed rozwojem Deep Learning), jest zarazem silnie wrażliwy na niewłaściwy krok i może "zapamiętać szum", przeuczając się drastycznie na zbiorze treningowym.

3.2. Wpływ współczynnika uczenia (learning_rate)

Parametr kontroluje, jak silny ułamek błędów naprawia każde kolejne drzewo z rzędu. Niska wartość czyni maszynę ostrożną, ale wymusza budowę gigantycznej serii drzew. Duża wartość gwarantuje gwałtowne zmiany w wadze, ale grozi pominięciem optimum globalnego.

learning_rate	Test Balanced Acc.	Test RMSE
0.01	0.5000	14.140
0.05	0.5000	14.171
0.1	0.5000	14.205
0.2	0.5000	14.314

Wyłoniono tu wysoce interesujący trend odwrotny. Z powodu gigantycznej liczności szumu w informacjach ankietowych, zastosowanie wyższych kroków kroku uczenia (np. 0.2) doprowadziło wręcz do osłabienia modelu. Gradient Boosting uczył się zbyt gwałtownie reagować na rzadkie przypadki socjologiczne. Wdrożenie powolnego, metodycznego podejścia na pułapie wagi 0.01 dało rewelacyjny wynik regresyjny rzędu 14.14, bijąc na głowę domyślnie ułożone Lasy Losowe.

3.3. Wpływ głębokości i liczby estymatorów

Sprawdzono, jak płytkie drzewa składowe oraz ich wolumen wpływały na maszynę Gradient Boosting przy zablokowanym `learning_rate = 0.1`.

max_depth	Test RMSE	n_estimators	Test RMSE
2	14.167	50	14.174
3	14.205	100	14.205
5	14.413	200	14.287
-	-	300	14.338

Dowodzi to kluczowego dogmatu optymalizacji Boostingu. Aby uzyskać fenomenalne wyniki bez zjawiska overfitu, pojedyncze drzewo w maszynie musi być ułomne i głupie. Głębokość drzew decyzyjnych w środku maszyny oparta na wartości ledwie 2, zagwarantowała wynik lepszy od drzew 5-poziomowych. Ograniczenie iteracji modelu do 50 estymatorów chroni system przez dopasowywaniem reguł pod pojedyncze wiersze w tabeli demograficznej.

3.4. Podsumowanie analizy Gradient Boosting i klasyfikacji

To właśnie w ramach testów modelu Gradient Boosting obnażono najbardziej zwodniczą naturę tego zbioru, jeśli chodzi o klasyfikację (`Divorce_Status`). Jak ukazują kolumny "Balanced Accuracy", w każdej badanej iteracji model plasuje się konsekwentnie w rejonach ~50% skuteczności zbalansowanej (co z technicznego punktu widzenia jest rzutem monety), mimo iż tradycyjne Accuracy (nieuwzględnione w tabeli) wynosiło ok. 90%. Udowodniło to nieprzydatność danych w celu separacji tych dwóch ekstremalnie nierównych podzbiorów, zmuszając promotorów projektu do modyfikacji wstępnych celów na badanie regresji stażu, która z kolei oddała w ręce badaczy wysoce poprawne wskaźniki błędów na pułapach 14 lat tolerancji predykcyjnej dla uśrednionych grup statystycznych.

4. Wnioski końcowe i Feature Importance

Przeprowadzona rozległa analiza czterech klasycznych algorytmów (od prymitywnych wektorów geometrycznych K-NN, po zaawansowane sekwencje w Gradient Boosting)

na bazie danych *HinduskieRomanse*, pozwoliła na sformułowanie jednoznacznych i wartościowych merytorycznie wniosków naukowych.

1. **Ważność Cech i Dekompozycja Szumu (Feature Importance):** Badając wagi dystrybuowane na poszczególne kolumny przez Random Forest dowiedziono, że czynniki o podłożu kulturowym i religijnym (np. różnice wyznania, rodzaj aranżacji, posag), mają znaczenie oscylujące wokół błędu statystycznego. Siłę uciążową klasyfikatorów wspierają wyłącznie: Years Since Marriage oraz Age at Marriage (ponad 30% wpływu). Algorytm wykazał czysto pragmatyczne podejście.
2. **Hierarchia mocy modeli:** Zestawienie całościowe wyników dla regresji wyłania model sekwencyjny Gradient Boosting jako bezapelacyjnego zwycięzcę tego starcia (RMSE sprowadzone do rejonu **14.14** lat z wykorzystaniem bardzo płytkich i ostrożnych iteracji). Random Forest, uplasowany niewiele z tyłu (RMSE **14.22**), udowodnił jednak miażdżącą przewagę pod kątem komfortu pracy: nie wymagał on bowiem agresywnej regularyzacji i podawał wysoce stabilne uogólnienia już na ustawieniach domyślnych, stanowiąc narzędzie typu Plug&Play. Modele takie jak K-NN całkowicie poległy w zetknięciu z gęstą strukturą 39-wymiarowych danych pochodnych, wyrzucając błędy o klasę gorsze od układów opartych na podziałach węzłowych.
3. **Limit Predykcyjny Zjawisk Społecznych:** Próg 14 lat dla błędu pierwiastkowego (RMSE) oraz analogiczne odchylenia dla MAE stanowią fundamentalne podsumowanie specyfiki badań demograficznych. Podczas gdy modele inżynierskie mogą dążyć do R^2 bliskiego jedynce, decyzje o rozwiązaniu węzłów małżeńskich należą do stochastycznych wyborów pojedynczych jednostek ludzkich. Uzyskany próg regresyjny stanowi absolutną górną granicę informacyjną, jakiej można zażądać od maszyny karmionej statycznym ujęciem kilkudziesięciu danych ankietowych w pojedynczym rzucie czasu. Wykazano tym samym, dlaczego badanie psychologii i społeczeństwa wymyka się prostym paradygmatom uczenia algorytmicznego.